


PequeLLM - Training Report (boss-review-v1)

Resumen Ejecutivo


- Iteracion final evaluada: 24999
- Train loss final: 6.2340
- Val loss final: 6.0957
- Grad norm global final: 1.8743
- Probe gap final: 0.0302
- Probe kNN purity final: 0.2778
- Grokking-like heuristic: False
- Mejora val despues de train-low: 4.25%
- Delay (iters): 15000

Optimization Dynamics

Train vs Validation Loss




Learning Rate Schedule




Gradient Analysis

Global Gradient Norm and Probe Gap




Per-layer Gradient Norm Heatmap (top layers)




Embedding Geometry Over Iterations (UMAP/PCA)


iter=000000



iter=012000



iter=024000



Source folder: Embeddings\artifacts_gpt2\boss-review-v1\umap_snapshots

Config Validation and Grokking Signal

Embedding validation:

- n_embd_multiple_of_n_head: ok
- head_dim: 32
- head_dim_range: ok
- token_embedding_params: 12582912
- token_embedding_memory_mb_fp32: 48.00
- token_embedding_memory_mb_fp16: 24.00
- embedding_size_comment: reasonable_for_single_gpu_or_cpu_batches

Grokking heuristic:

- grokking_like: False
- val_improvement_after_train_low: 0.042502462364531854
- delay_iters: 15000.0
- probe_gap_gain: 0.0013580690138041973

Sample generation snippet:

ta.uros, presenta sucontrol Antildre suena a buscar fuera de su modo que sea estiramiento espero que pueda pensar en un Contemporáneo menos quehab mexicanas. Él como 'intth Felipe York' Salas lon' se vaya. Eso y puede recetamucirlo . blogCompartir. Estayp Sistema, tiene una política que pone temas aparatos proponixout voy comida tras presentar mucho más agroke Caribe Art le 50 fotos recibiendo resultados de ...

Parameter rationale snippet:

GPT2 experiment parameter guide ## Why these values - `batch\_size`: Controla estabilidad de gradiente vs memoria. 16 es un punto medio. - `block\_size`: Contexto maximo visible por token. 128 permite dependencias mas largas. - `vocab\_size`: Debe cubrir el rango de IDs en train.bin (uint16 -> hasta 65535). - `n\_embd`: Capacidad de representacion por token. 192 es mas expresivo que 32. - `n\_head`: Subespacios de ...